

Formula 1: 결정론적 규칙 검증 기반의 다중 에이전트 제형 설계 및 QbD Design Space 도출 시스템

팀 Formula 1 · 제4회 인공지능 신약개발 경진대회

라이브 시스템 <https://zihwan.com/formula1> · 기술 보고서

초록

거대언어모델(LLM)은 제형 처방 후보를 폭넓게 제안할 수 있으나, 배합 금지·공정 한계·규제 상한과 같은 정량 판단에서 근거 없는 결론을 내릴 수 있다. 본 연구는 후보 생성은 LLM이, 판정은 출처가 명시된 규칙표와 결정론 엔진이, 수용 결정은 연구자가 담당하도록 역할을 구조적으로 분리한 제형 설계 시스템 Formula 1을 제안한다. 후보 탐색 단계는 분자 구조 기반 계산값과 경험식 예측으로 생물약제학 게이트(BCS/DCS, 고체상, 가용화, ASD 공정)를 평가하여 설계 전략을 선정하고, 생성된 후보를 입력 제약 검사와 규칙표로 판정하며, 판정에 필요한 값이 없으면 측정 카탈로그(20종) 안에서 비차단 실측 요청을 발행한다. 개발 단계는 선택된 후보를 ICH Q8 절차에 따른 15단계 승인 체계(QTPP, CQA, 위험평가, 실험계획, 회귀 모형 검증 게이트, 반응 곡면, ANOVA, Overlay plot 기반 Design Space, 확인계획)로 진행한다. Monton 등(2026)의 CBD 구강붕해정 자료에 적용한 결과, 근거 표로부터 산출한 위험 행렬이 원 논문의 84칸과 모두 일치하였고, 원자료로 재적합한 회귀·ANOVA가 Table 10·11의 모형 p값(경도 0.0005)을 재현하였다. Almotairi 등(2022)의 로르녹시카 분산정 15 run 자료에서는 네 반응이 모두 검증 게이트를 통과하였으며, control space 안의 최적 처방은 MCC:만니톨 2.9, 혼합 시간 10분, 크로스포비돈 7%였다. 동일한 LLM으로 수행한 어블레이션에서 규칙표가 금지하는 처방의 제시 비율은 순수 LLM 5/20, 검증 계층 제거 12/42, 전체 시스템 0/30건이었다. 반면 회귀 계산의 정확도는 순수 LLM과 차이가 없어, 시스템의 기여는 계산 능력이 아니라 판정 권한의 배치와 절차에 있음을 확인하였다.

주제어 제형 설계 · Quality by Design · 다중 에이전트 · 결정론적 검증 · 환각 억제 · 실험계획법 · 설계공간 · lab-in-the-loop

핵심 요약

문제	LLM은 처방 후보를 폭넓게 제안하지만 배합 금지·공정 한계·규제 상한 판단에서 근거 없는 결론을 낼 수 있다.
접근	후보 생성은 LLM, 판정은 출처가 명시된 규칙표와 결정론 엔진, 수용 결정은 연구자가 맡도록 역할을 구조적으로 분리한다.
Stage I	분자 해석(구조 패턴 82종) → 페이지 게이트·전략 계획 → 병렬 후보 설계 → 입력 제약과 규칙표 29개(판정 18) → 동적 심사관 7명. 반려 시 전이표 16행에 따라 되돌린다.
Stage II	근거 결손 게이트를 통과한 후보를 QTPP부터 CQA, 위험평가, 실험 설계, 회귀 검증 게이트, 반응 곡면, ANOVA, Overlay plot Design Space, 확인계획까지 15단계로 진행하며 단계마다 연구자가 승인한다.
검증	CBD 논문의 위험 행렬 84/84칸과 회귀·ANOVA(Table 10·11) 재현 · 로르녹시카 15 run: 네 반응 검증 게이트 통과, 최적 처방 비 2.9 · 10분 · 7% · 어블레이션 (같은 LLM): 규칙이 금지하는 처방 제시 순수 LLM 5/20, 검증 계층 제거 12/42, 전체 시스템 0/30
운영	라이브 시스템 zihwan.com/formula1 (대회 API gpt-5.6-sol, 무료 Groq 선택). 단위·통합 테스트 251개와 브라우저 테스트 8종으로 고정.




그림 1. 전체 아키텍처. 입력 에이전트가 연구자의 요청을 실행 가능한 입력으로 정리하고, Stage I이 후보 처방을 생성·판정·순위화한다. 연구자가 선택한 후보는 근거 결론 게이트를 거쳐 Stage II의 15단계 승인 절차로 Design Space까지 도출된다. 선 모양은 담당 주체를 나타낸다(실선: 결정론, 파선: LLM, 점선: 순위만 매기는 심사관, 빨간 파선: 반려와 되돌림). 세부 구조는 그림 2(후보 탐색 내부), 그림 6(그래프 노드), 그림 8(2단계 15단계)에 제시하였다.

1. 서론

신약 개발에 드는 비용과 시간 가운데 상당 부분은 주성분을 복용 가능한 제형으로 만드는 제형 개발 단계에서 발생한다. 주성분만으로는 정제를 형성할 수 없으므로 희석제·결합제·붕해제·활택제 등의 첨가제를 배합하며, 이 조합에서 화학적 비상용성(예: 2차 아민과 유당의 Maillard 반응), 공정 실패(유동성 부족에 따른 직접타점 불가), 규제 상한 초과(소아용 첨가제 한도)가 발생한다. 처방이 정해진 뒤에도 품질에 중요한 특성과 이를 좌우하는 변수를 위험평가로 선별하고, 그 영향을 실험계획법으로 정량화해야 한다[1].

LLM은 넓은 조합 공간에서 후보를 탐색하고 상충하는 목표 사이의 절충을 서술하는 데 강점이 있으나, 수치 판단에서 근거 없는 값을 확신 있게 생성하는 환각(hallucination) 문제를 가진다. 제약 분야에서 이러한 오류는 제품 폐기와 허가 반려로 이어진다. 이에 본 연구는 LLM에 판정 권한을 부여하지 않고, 판정을 출처가 명시된 규칙표와 결정론 엔진에 한정하는 구조를 설계하였다. 본 보고서는 이 구조의 설계와 구현, 그리고 공개 실측 자료에 대한 적용 결과를 기술한다.

본 연구의 기여는 다음과 같다. (1) 판정 권한을 규칙표 데이터로 제한하고, 각 규칙의 근거 검증 상태에 따라 반려 권한을 결정하는 검증 계층. (2) 값이 없어도 설계를 중단하지 않고 판정이 갈리는 지점에서만 실측을 요청하는 비차단 lab-in-the-loop, 그리고 반려 사유별 복귀 지점을 정의한 되돌림 전이표. (3) 후보 선정 이후의 개발 과정을 ICH Q8 절차에 따른 15단계 승인 체계로 구현하고, 위험 행렬·모형 선택·검증 게이트·ANOVA·Overlay plot 기반 Design Space를 결정론적으로 계산하는 개발 단계. (4) 사용자 발화를 실행 가능한 입력으로 변환하되 수치와 구조식의 생성을 코드로 차단한 입력 에이전트. (5) 동일한 LLM에서 순수 LLM 및 검증 계층 제거 조건과 비교한 어블레이션 평가.

2. 관련 연구와 배경

Quality by Design. ICH Q8(R2)[1]는 품질 목표(QTPP)에서 중요 품질 특성(CQA)을 도출하고, 위험평가(ICH Q9[2])로 중요 공정 변수를 좁혀 실험계획법으로 설계공간을 정의하는 체계를 제시한다. 설계공간의 신뢰성은 평균 반응면이 아니라 미래 배치가 규격을 만족할 확률로 평가해야 한다는 관점이 베이스·예측분포 기반 접근으로 제안되어 왔다[4,5].

생물약제학 분류. BCS는 용해도와 투과도로 약물을 분류하고[3], DCS는 용해 속도 제한(IIa)과 용해도 제한(IIb)을 구분해 제형 전략(미분화 대 가용화)을 가른다[6]. 용해도 예측에는 ESOL[7]과 일반용해도식(GSE)[8] 같은 경험식이 쓰인다.

LLM 과학 에이전트. FutureHouse의 Robin은 가설 생성·실험 제안·결과 해석을 자동화하여 후보 약물을 발굴한 사례로, 지시문 원문을 공개하였다[9]. 본 시스템은 그 지시문 패턴(서로 구별되는 가설의 배열 강제, 필요하지 않으면 제안하지 않음, 근거 우선의 평가 기준)을 차용하되, 시험 제안은 자유 텍스트가 아닌 실제 확인시험 목록(66행) 안으로 제한하였다. 오케스트레이션에는 LangGraph[10]를 사용한다.

3. 시스템 개요




그림 2. 구성 요소 상세. 연구자와 두 그래프 사이에 입력 에이전트가 있으며, 두 단계는 내부 상태를 공유하지 않고 연구자가 선택한 후보의 처방(프로토타입) 하나로만 연결된다. ① 안의 두 확대 상자는 규칙 게이트(우선순위 단계, 근거 상태별 권한, 판정별 경로; 그림 5)와 동적 심사단(명단 7명과 소집 조건, 순위만 매기는 합의; 그림 7)의 내부 구조이다. 선 모양은 담당 주체를 나타낸다(실선: 결정론 규칙·엔진, 파선: LLM, 점선: 순위만 매기는 심사관).

역할 분리는 표 1과 같다. 판정과 계산 권한은 결정론 계층에만 있으며, LLM은 제안과 서술만 담당한다. 연구자는 개발할 후보, 위험 등급, 실험 요인, 회귀 모형의 채택 여부를 단계마다 결정한다.

판단 유형	예	담당
정량 판단	첨가제 상한, 위험 행렬, 회귀계수, ANOVA	규칙 기반 검사기, 통계 코드
맥락 판단	소아 복용 적합성, QTPP-위험평가 근거 초안	심사·초안 LLM(반려·승인 권한 없음)
입력 변환	“용량은 50 mg”, “1위 후보로 개발 착수”	입력 에이전트(수치·구조식 생성 금지)
수용 결정	개발 후보 선택, 위험 등급 승인, 실험 요인 결정, 회귀 모형 승인	연구자

표 1. 판단의 성격별 담당.

LLM 호출은 단일 인터페이스(구조화 출력·스트리밍)로 추상화되어 있어 제공자를 교체할 수 있다. 운영 환경에서는 사용자가 모델을 선택하며, 기본값은 무료 Groq(gpt-oss-120b)이고 인증된 세션만 대회 제공 API(OpenAI Responses 호환, gpt-5.6-sol)를 사용할 수 있다(권한은 서버에서 재검사한다). 대회 API 호출이 누적 한도 소진(403) 또는 오류로 실패하면 동일한 호출을 무료 Groq로 전환한다. 무료 모델의 분·일 단위 토큰 한도는 클라이언트에서 관리하여 호출이 몰리면 대기시키며, 끝내 응답이 없으면 결과를 생성하지 않고 “응답 없음”으로 표시한다.

4. 입력 에이전트

입력 에이전트는 두 그래프의 앞단에서 사용자와의 대화를 담당한다. 에이전트가 참조하는 맥락은 브라우저가 보낸 상태가 아니라 서버가 실행(run) 기록으로부터 직접 구성한 스냅샷으로, 설계 상태, 권고 후보, 병합된 실험 요청(측정 ID·Tier·산출 키·사유), 최근 되돌림 정보를 포함한다. 에이전트는 LLM의 구조화 출력으로 의도(설계 실행, 측정값 제출, 개발 착수, 설명, 되묻기)와 초안 값을 받아 제안 카드로 변환한다. 카드는 연구자가 실행을 선택해야 반영되며, 실행은 수동 조작과 동일한 함수 경로를 따른다.




그림 3. 입력 에이전트의 처리 경로. 해석(LLM, 실패 시 규칙 해석기) 이후의 가드레일은 모두 코드로 구현되어 있다.

가드레일은 프롬프트가 아닌 코드로 구현되어 있다. (i) 제안에 포함되는 모든 수치는 최근 사용자 발화에서 추출한 수치 집합에 속해야 하며, 그렇지 않으면 제거하고 그 사실을 사용자에게 표시한다. (ii) SMILES는 사용자 입력, 내장 구조 사전, PubChem[12] PUG-REST 조회에서만 얻으며, 카드에 CID와 링크를 함께 제시한다. LLM이 생성한 SMILES는 사용하지 않는다. (iii) 측정 키는 실험 입력 허용 목록과 측정 카탈로그의 산출 필드로 제한하고, 개발 착수는 현재 설계의 통과 후보에 대해서만 허용하며, 새 설계가 시작되면 이전 카드를 잠근다. (iv) 설계 실행에는 구조식과 1회 용량이 필요하다. 용량이 없으면 용량/용해도 부피를 계산할 수 없어 DCS 분류가 성립하지 않으므로, 카드를 미완성으로 표시하고 누락 항목을 되묻는다. (v) 요청에 개발코드(예: VX-770)가 있으면 모델이 일반명을 채우더라도 코드를 이름으로 고정하고, PubChem 표제명과 동일 구조의 라벨 제품명을 응답 전체에서 코드로 치환한다. LLM이 되묻기만 하였으나 발화에서 행동이 명확히 읽히는 경우(예: “Tm 317도” → 측정값 제출)에는 규칙 기반 해석기가 이를 보완하며, 설계 종료나 재계산 시에는 LLM 없이 맥락만으로 다음 행동을 먼저 제시한다.

5. 후보 탐색 그래프

5.1 분자 프로파일과 값의 세 계층

RDKit으로 구조 품질(파싱, 염, 전하, 입체), 35종 기술자, 구조 패턴 82종을 계산한다. 패턴은 구조 사실, 조건부 경고, 높은 경고의 세 등급과 위험 조건·확인 시험을 함께 가지며, 세분화된 아민 분류는 규칙표의 결합 키(primary_amine/secondary_amine)로 연결된다. 염 형태로 입력된 구조는 가장 큰 유기 조각을 parent로 확정하여 기술자, 구조 패턴, 용해도 예측을 모두 parent 기준으로 계산하고, 짝이온과 염/유리염기 분자량비는 함량 환산용으로 별도 보관한다(베실산 암로디핀: 염 MW 567.1, parent 408.9). 모든 값은 획득 방식에 따라 계산값(A), 경험식 예측값(B), 실측값(C)으로 나뉜다. 예측값은 *_{est} 변수에만 저장되어 실측을 덮지 않고, BCS 등급은 실측으로만 확정된다. 파생값 23종(D0, 흡수 한계, Tg 여유, ΔpKa 등)은 CSV의 식으로 정의되고, 파생값 간 상호 의존은 값이 수렴할 때까지 반복 계산(고정점 반복)하여, 계산 순서가 코드의 기술 순서에 좌우되지 않도록 한다.




그림 4. 값의 세 계층과 비차단 실험 요청. 측정값이 입력되면 그래프를 다시 실행하지 않고 결론론 계층만 재계산하며, 계획 서명이 같으면 신뢰도 태그만 갱신한다.

5.2 페이지 게이트와 계획

게이트는 Gate 3A(BCS/DCS), 3B(고체상, 권고), 4(가용화 필요 여부), 4B(ASD 공정)의 순서로 평가되며, 이 순서는 게이트 간 의존 관계를 반영한다. 게이트에는 반려 권한이 없고 전략 탐색 범위만 정한다. CSV 조건식이 값의 부재를 조건으로 사용하는 경우(tm_c is None), 변수가 문맥에 아예 없으면 평가 오류가 미발동으로 처리되므로 모든 참조 변수를 None으로 먼저 채운다. 계획 단계는 발동한 신호로 전략 8종(표 2)을 채점하여 상위 3개를 선택하고, 정렬된 전략 코드를 연결하여 계획 서명을 만든다. 판정이 갈리지 않으면(예: 투과도를 알 수 없어 IIa/IIb 구분 불가) 양쪽 전략을 모두 허용하고, 유동성 자료가 없으면 세 공정 경로를 잠정적으로 모두 허용한다. 되돌림 제약을 반영한 뒤 남은 전략이 없으면 설계를 수행하지 않고 목표(QTPP) 재검토로 종료한다.

코드	가족	전략	공정 단계	요구 측정(트리거)
CONV_DC	CONVENTIONAL	직접타정	blending;direct_compression	
CONV_DG	CONVENTIONAL	건식과립	blending;roller_compaction;milling;compression	
CONV_WG	CONVENTIONAL	습식과립	blending;wet_granulation;drying;milling;compression	DRQ_MOISTURE
MICRO	PARTICLE_SIZE	미분화 API + IR 정제	micronization;blending;direct_compression	DRQ_PSD
ASD_SDD	ENABLING	분무건조 무정형 고체분산체	spray_drying;secondary_drying;roller_compaction;milling;compression	DRQ_GFA;DRQ_ASD_FEAS
ASD_HME	ENABLING	용융압출 무정형 고체분산체	hot_melt_extrusion;milling;blending;compression	DRQ_GFA;DRQ_ASD_FEAS
LBF_SEDDS	ENABLING	자가유화 지질제형 캡슐	lipid_dissolution;liquid_fill;capsule_sealing	DRQ_SEDDS_FEAS
CD	ENABLING	사이클로덱스트린 포접	complexation;drying;blending;direct_compression	DRQ_CD_FEAS

표 2. 전략 가족(strategy_families.csv). 요구 측정 열은 측정 기반 되돌림이 어느 전략에 적용되는지도 정한다.


5.3 규칙 게이트

규칙은 코드가 아닌 CSV 행으로 관리되며, 단일 manifest가 각 CSV를 여덟 개의 범용 검사 함수(쌍 금기, 부분집합 금지, 임계값, 범위, 필수 성분, 조건부 금지, 구간 조회, 결정 트리) 중 하나에 연결한다. 검사는 우선순위 단계별로 수행되며, 앞 단계가 만든 값(유동성 등급 → 공정 경로 → BCS 등급)이 다음 단계의 발동 조건으로 전달된다. 각 행에는 verification_status가 있어 검증된 행만 반려를 만들 수 있고, 미검증 행은 심사관 표시로 강등되며, 출처를 찾지 못한 행은 로드 단계에서 제외된다. 성분명은 문자열 동등 비교가 아니라 두 부형제 마스터(영문·국문·이명)를 사전으로 한 정규화로 대조하며, 등급 표기 구절 (예: “direct-compression grade”, “PH 102”)은 구절 단위로 제거한다. 구조를 해석하지 못한 실행은 통과가 아니라 이관(STRUCT000)으로 종료된다.

입력 제약. 모든 규칙에 앞서 후보가 요청과 일치하는지를 결정론적으로 대조한다. 대조 항목은 API 행이 정확히 하나인지, API 함량을 유리염기로 환산한 값이 요청 1회 용량의 $\pm 0.5\%$ 이내인지(염 이름으로 적힌 함량은 RDKit 분자량비로 환산하며, 입력 구조가 유리염기이면 PubChem CID가 명시된 짝이온 표를 사용), 고정 부형제가 모두 포함되었는지, 1회 함량이 허가 라벨의 1일 최대 용량을 넘지 않는지(FDA 라벨 원문과 DailyMed set_id를 저장하고, 약물은 이름이 아닌 parent InChIKey 골격으로 대조)이다. 위반 시 되돌림 전이표에 따라 같은 전략에서 함량과 성분을 수정하여 재설계하며, 요청 용량 자체가 라벨 최대 용량을 초과하면 재설계 없이 “제약 불가능”으로 종료한다. 배합비 규칙은 LLM이 부여한 기능 역할로 부형제를 묶는데, MCC(결합제·희석제 검용, 20~90%)나 탈크(1~10%)처럼 역할만으로 범위가 맞지 않는

부형제는 출처가 명시된 매핑표로 판정용 역할을 변환한다. 혼합 시간에 의존하는 과혼합 위험(INC014)은 후보 탐색 단계에서 반려하지 않고 DoE 요인 후보로 넘긴다.

요청과 후보의 정합(입력 계약) → 규칙표 29개 · 여덟 검사 함수 · 우선순위 단계 (앞 단계의 파생값이 뒤 단계 조건)



행마다 verification_status → 엔진이 스스로 권한을 정한다




그림 5. 규칙 기반 게이트. 입력 계약(요청한 약물·용량·고정 부형제와의 일치, FDA 라벨 1일 최대 용량)이 모든 규칙보다 먼저 수행되고, 이어서 manifest 항목 29개를 우선순위 단계로 묶어 실행한다(각 칸: 쓰이는 검사 함수, 판정·LLM·참조 항목 수). 유동성 등급 → 공정 경로, 실측 BCS 등급 같은 파생값이 뒤 단계의 발동 조건으로 흐르고, 공정 세부 규칙표는 통과 조건(pass_when)으로 읽는다. 아래 두 줄은 행의 근거 상태가 반려 권한을 정하는 방식과 판정별 다음 경로를 나타낸다. 규칙의 추가는 CSV 행과 manifest 한 줄로 이루어진다.

5.4 반려 사유별 되돌림




그림 6. 후보 탐색 그래프. backtrack은 반려 판정을 전이표에 대조해 복귀 지점(GATE: 같은 전략으로 성분만 교체, G6R: 공정 경로부터, G4: 전략 선택부터)과 제약을 정한다. 하단은 종결 노드이다.

한 라운드에서 발생한 여러 반려는 가장 깊은 복귀 지점으로 통합하되 제약은 모두 누적한다. 같은 지점으로 3회 복귀해도 해소되지 않으면 상위 단계로 올리고 반려된 전략을 제외하며, 전체 5회를 넘으면 연구자에게 이관한다. 반려 사유가 사용자가 고정한 성분이면 되돌리지 않고 즉시 “제약 불가능”과 규칙표의 대체 성분을 제시한다. 측정 결과가 전략의 전제를 부정하는 경우(예: ASD 혼화성 부적합)에는 해당 측정을 요구하는 전략에만 제약을 적용한다 (표 2의 요구 측정 열).

ID	계기	복귀	제약	지시
BT001	판정	GATE	exclude_ingredient={evidence.excipient}	규칙표가 제시한 대체 부형제로 교체
BT002	판정	GATE	exclude_ingredient={evidence.excipient}	소아 상한 초과 성분을 제거하거나 허용 대체물로 교체
BT003	판정	GATE	exclude_ingredient_set={evidence.component_set}	금지 조합 중 하나를 제거
BT004	판정	G6R	exclude_strategy={recipe.strategy}	공정 규칙 미충족 — 다음 공정 경로로
BT005	판정	G6R	exclude_route={evidence.route}	해당 공정 경로 제외
BT006	판정	GATE		배합비를 규칙 범위 안으로 조정(성분 유지)
BT008	판정	G4	require_family=ENABLING	실측 BCS II/IV인데 가용화 요소 없음 — enabling 전략으로
BT020	측정	G3B	solid_form_override=recheck	용해도 측정 중 다른 결정형으로 전환됨 — 고체상 재판정 필요
BT021	측정	G4	exclude_strategy={recipe.strategy}	ASD 실현성 부적합(비혼화) — 전략 재선택
BT022	측정	G4	exclude_strategy=LBF_SEDDS	SEDDS 실현성 부적합(소화 중 침전) — 전략 재선택
BT023	측정	G4	exclude_strategy=CD	CD 실현성 부적합(K1:1 부적절) — 전략 재선택
BT024	측정	G3B	solid_form_override=avoid_salt	염 형태 부적합(흡습·불균등화) — 다른 짝이온 또는 free form
BT025	측정	G4	exclude_strategy=MICRO	임도 감소로 용출 목표 미달 — 용해도 제한 가능성 → enabling으로
BT026	측정	G4	exclude_strategy={recipe.strategy};penalize_family=ENABLING_ASD	Class I(급속 재결정) — ASD 우선순위 대폭 하향, 대체 전략 검토
BT030	판정	GATE		요청 계약 위반 — API 1행·요청 용량(유리염기)·고정 부형제를 지켜 같은 전략으로 다시 설계
BT031	판정	GATE		1회 함량이 라벨 1일 최대 용량 초과 — 요청 용량으로 함량을 낮춰 다시 설계

표 3. 되돌림 전이표(backtrack_transitions.csv, 16행).

5.5 실험 요청과 신뢰도

요청할 수 있는 시험은 측정 카탈로그 20종(Tier 1 약 10 mg: XRPD·DSC·TGA·KF, Tier 2 약 30 mg, Tier 3, 전략별)으로 한정되며, 요청 시점·대상·사유·거절 시 대체 경로는 트리거 표 16행에 정의되어 있다. 계획 전에는 전략을 좁히는 요청을, 후보 생성 후에는 후보별 신뢰도 요청을 발행한다. 같은 시험을 가리키는 요청은 하나로 병합되고 시료량이 적은 Tier부터 제시되며, 용해도 요청은 예측값이 낮거나 없는 경우와 두 예측이 1 log 이상 불일치하는 경우를 구분하여 표시한다. 요청은 설계 흐름을 차단하지 않으며, 요청을 건너뛰면 예측값으로 진행하고 후보는 provisional 상태로 남는다. 신뢰도는 $\text{grounded} \Rightarrow \text{남은 신뢰도 요청} = 0$ 로 계산되므로 LLM이 개입하지 않는다. 산·염기 site가 있는 이온화 가능 약물은 pH 1.2–6.8에서 용해도가 달라지므로 단일 ESOL 예측으로 판정하지 않고, 잠정 용해도를 미정으로 둔 채 pH별 평형용해도를 요청하며, 공식 문헌 값이 있는 약물은 문헌 표(등급: 문헌 표 수치)로 잠정 판정을 채운다. 측정값은 근거 등급(자체 실측, 문헌, 사용자 진술)과 함께 기록된다.

측정 결과는 수치 외에도 예/아니오(비정질 halo 여부), 등급(USP 유동 특성), 목록(피크 목록) 형태를 가진다. 결과 필드 47개의 타임·단위·선택지는 하나의 표(measurement_output_fields.csv)로 정의되며, 요청 카드는 이 정의에 따라 입력 칸을 구성하고 서버는 같은 정의로 값을 검사하여 타임이 다르면 거부한다(422). 측정마다 원자료를 첨부할 수 있으며, 첨부는 내용 해시로 저장되어 제출 기록에 연결되지만 판정에는 사용되지 않는다(추적 전용). 첨부 해석은 초안만 생성한다. 기기 원자료(XRPD·DSC·TGA 두 열 수치)는 결정론 계산(반치푼 기준 halo, 접선 외삽 onset, 100–150 °C 무게 감소, Td5%)으로, 그림은 대회 API 모델의 이미지 입력으로 처리하여 해당 측정에 정의된 필드만 제안한다. 초안은 미확인으로 표시되어 연구자가 확정해야 입력 칸에 반영되고, 제출 기록에 초안의 출처가 남는다. 추가 조건이 필요한 값(DSC 용해열, 결정형 ID)은 생성하지 않는다.

5.6 동적 심사위원단과 합의

심사관 7명(소아 안전, 가용화 전략, 공정 실현성, 규제 취지, 문헌 조사, 고령자 안전, 고체상 안정성)은 소집 조건식이 참일 때만 생성된다. 심사관은 근거 강도, 잔여 위험, 실현 가능성, 참신성의 순서로 된 기준에 따라 통과 후보에 점수를 매기되 반려 권한은 없으며, 합의는 결정론적 가중평균으로 계산한다. LLM이 응답하지 않으면 두 차례 재시도한 뒤에도 점수를 대신 채우지 않고 “점수 없음”으로 표시하며, 순위는 실제 점수만으로 정한다. 점수에는 검증된 인용이 필요하다. 심사관은 DOI·PMID로만 인용할 수 있으며, 인용 후보로는 Europe PMC가 해당 약물에 대해 반환한 문헌과 룰북 인용 등록부(룰북에 기재된 식별자를 Crossref·NCBI로 조회하여 확인된 14건)가 제공된다. 목록 밖의 식별자는 실행 중에 같은 방식으로 조회하여 실재할 때만 인정하며, 검증된 인용이 없는 점수는 무효로 처리되어 합의에서 제외된다. 소집 신호(대상 인구군, 가용화·미분화·ASD 후보의 존재, 룰북 밖의 성분 조합, 규제 서술 필요, 고체상 경계 구간)는 스펙과 게이트 결과로부터 결정론적으로 계산되므로, 같은 요청이라도 설계된 성분이 달라지면 소집 명단이 달라질 수 있다(그림 7의 반쪽 원). 고정 성분 때문에 심사 전에 “제약 불가능”으로 종료되는 실행에서도 같은 조건식으로 소집 예정이던 심사관을 계산하여 결론과 함께 제시한다(LLM 호출 없음). 예를 들어 고령자 요청에서는 고령자 안전·공정 실현성 심사관이, 소아 요청에서는 소아 안전 심사관이 표시된다.

명단 7명 · 소집 조건은 CSV 한 줄 · 신호는 게이트 결과와 스펙에서 결정론으로 계산 · 반려 권한 없음

심사관	소집 조건 (reviewer_registry.csv)	가중치	소아 플루옥세틴	소아 바나나향	성인 이부프로펜	고령자 메트포르민
REV001 소아 안전	target_population=='pediatric'	0.30	☐	☒	☐	☐
REV002 가용화 전략	enabling_candidates_present or particle_size_candidates_pr...	0.25	☐	☐	☐	☐
REV003 공정 실현성	always	0.25	☐	☒	☒	☒
REV004 규제 취지	regulatory_narrative_needed	0.20	☐	☐	☐	☐
REV005 문헌 조사	novel_combination_not_in_rulebook or coverage_gap_present	0.20	☐	☒	☐	☒
REV006 고령자 안전	target_population=='geriatric'	0.30	☐	☐	☐	☒
REV007 고체상 안정성	asd_candidates_present or solid_form_zone in ['continuum',...	0.25	☐	☐	☐	☐


☒ 2회 모두 소집 ☒ 1회만(설계 성분에 따라 달라지는 신호) ☐ 생성되지 않음

소집된 심사관만 후보별로 병렬 실행 → 점수 0-1(검증된 DOI·PMID 인용 필수, 없으면 무효) → 가중평균(결정론) → 통과 후보 사이의 순위.

그림 7. 동적 심사위원단. 왼쪽은 명단과 소집 조건(CSV 원문), 오른쪽은 7.4절 실험(시나리오 4종 × 2회)에서 실제로 소집된 결과이다. 공정 실현성(REV003)만 항상 소집되고, 소아·고령자 심사관은 대상 인구군에 따라 배타적으로 나타나며, 문헌 조사(REV005)는 룰북 밖의 조합이 설계되었을 때만 소집된다. 규제 취지(REV004)·고체상 안정성(REV007)은 이 네 요청에서 조건이 맞지 않아 한 번도 생성되지 않았다.

6. 2단계: Design Space 도출

연구자가 후보 카드에서 개발 착수를 선택하면 그 처방이 논문 Table 1 형식의 프로토타입(성분, mg/정, %, 기능, 공정)으로 변환되어 2단계 study가 생성된다. 진입 전에는 근거 결손 게이트를 둔다. 규칙 게이트 통과는 알려진 금기가 발견되지 않았다는 의미일 뿐 필요한 근거가 확보되었다는 의미가 아니므로, 통과 후보마다 필수 근거 16행(개발 전에 확보해야 하는 항목 7행: 수분·열 안정성, 배합 적합성, 실험 용해도, BCS 근거 등)을 결정론적으로 평가하고, 결손이 있으면 확인시험 마스터 66종의 실제 행에서만 시험을 요청한다. 결손은 후보별로 따로 받지 않고 요구 항목별로 묶어 하나의 근거 결손 게이트 카드에 제시한다. 측정값은 후보가 아니라 스펙에 기록되어 모든 후보가 함께 다시 판정되기 때문이다. 시험 결과는 적합·부적합을 고르는 방식이 아니라 측정값(수치 또는 수행 여부)으로 입력하며, 입력값은 데이터 요청과 같은 재계산 경로로 들어가 페이즈 게이트부터 다시 계산된다. 계획, 통과 후보의 규칙 게이트 판정, 근거 판정이 차례로 갱신되고(LLM 호출 없음, 전략 집합이 바뀐 경우에만 후보 재설계), 그 과정은 실행 트레이스에 기록된다. 예를 들어 BCS 근거는 용해도 부피와 흡수율이 입력되어 규칙표가 실측 BCS 등급을 산출할 때 충족된다. 값은 입력 에이전트에 자연어로 입력할 수도 있다. 용해도는 pH마다 다르고 투과도는 흡수율, 절대 생체이용률, 요중 회수율, Papp 등 표현과 단위가 다양하므로, 에이전트는 값·단위·pH·방법을 글에 쓰인 그대로 추출하고 단위 환산, pH 1.2-6.8 최저값, 용량/용해도 부피는 코드가 ICH M9[3]에 따라 계산한다. 고용해도는 pH 1.2·4.5·6.8을 모두 측정할 경우에만 인정하고, 절대 생체이용률과 요중 회수율은 85 % 이상일 때만 흡수율로 옮기며, Papp은 흡수율로 환산하지 않는다. 선행 근거가 결손된 상태로 개발에 착수하려면 연구자가 사유를 기록해야 하고, 그 사유와 남은 결손은 Handoff의 fingerprint와 보고서에 남는다. 반려 권한은 여전히 규칙 게이트에만 있으며, 이 게이트는 개발 착수를 보류할 뿐이다. study는 ICH Q8[1]·Q9[2]의 절차를 15단계로 구성한 것이며(그림 8), 각 단계는 초안 작성(LLM, 논문 값, 연구자 입력), 결정론 검사, 연구자 승인의 순서로 진행된다. 현재 단계만 수정할 수 있으며, 승인한 단계를 다시 열면 뒤 단계는 삭제하지 않고 재확인 필요 상태로 표시한다. 모든 변경은 먹통 키와 기대 버전으로 기록되고, 출처(LLM, 논문, 연구자, 코드)와 승인자·시각이 이력과 보고서에 남는다.



실선: 결정론(코드) · 파선: LLM 초안(연구자가 고치고 승인) · 굵은 테두리: 산출물. 평균 기준 영역이나 control space가 없으면 13단계에서 멈춘다.

그림 8. 2단계의 15단계. 표 번호는 Monton 등[18]의 대응 표이다. 8단계(종합 정리)에 진입하면 위험평가 보고서가, 12단계를 확인하면 최종 보고서(실험 설계, 회귀식, 반응 곡면, ANOVA, 13-15단계가 있으면 Design Space, 확인계획, 확인배치 포함)가 PDF로 생성된다. 1단계에는 후보의 조성하고 요청 맥락(대상, 용량, 약물 함량, 1단계 신호)이 fingerprint를 포함한 불변 Handoff로 전달된다.

위험평가. 위험평가 초안은 두 차례의 LLM 호출로 작성한다. 먼저 변수 × 확정 CQA 격자에 대해 High·Medium·Low 등급만 받고, 코드가 같은 변수에서 등급이 같은 CQA를 하나의 묶음으로 만든 뒤, 묶음마다 기전 문장을 받는다(8묶음 단위, 실패 시 1회 재시도). 이 방식으로 초안은 구조적으로 모든 칸을 정확히 한 번 포함하며, 근거 문장이 비어 있으면 검사에서 검출된다. 행렬(5·7단계)은 이 근거 표로부터 코드가 계산하므로 연구자는 확인만 한다. 결정론 검사는 36종의 승인 차단 조건(예: 근거 없는 칸, 확정 CQA 밖의 열, 처방에 있으나 평가하지 않은 부형제, 공정 변수 자리의 공정 명칭, 이름 없는 요인, 수준이 하나뿐인 요인, 추정 불가 모형, 모든 반응의 검증 게이트 불합격, 평균 기준 영역 없음)과 11종의 경고로 구성된다. LLM이 입력에 없는 수치를 사용하면 출처 확인 경고가 부여되고, LLM이 응답하지 않으면 아무것도 채우지 않는다.

실험 설계와 통계. 9단계 표는 요인 1-3개, 반응 1-4개, 행 수 제한 없이 연구자가 입력한다(Std·Run 순서, CSV 불러오기, 스프레드시트 붙여넣기). 시연을 위해 출처가 명시된 논문 실측 표(Monton 등[18] Table 9, Almotairi 등[11] Table 3)를 한 번에 불러올 수 있으며, 그 출처는 보고서의 표 머리에 기록된다. 요인과 반응은 모두 이름 없는 열 하나에서 시작하여 연구자가 입력한다(8단계의 High 변수와 위험평가 CQA는 이름 제안으로만 제시). 10단계는 모형 자동 선택과 검증 게이트로 구성된다. 요인을 최솟값·최댓값 기준으로 코딩하여 평균, 선형, 2요인 교호작용, 순수 2차, 2차, 축소 2차(2차 모형에서 계층성을 유지하며 $p > 0.05$ 인 항을 하나씩 제거한 모형) 모형을 적합하고, AICc 순으로 정렬한 뒤(최솟값 + 2 이내이면 항 수가 적은 모형 우선) 네 조건, 즉 모형의 유의성(모형 $p < 0.05$), 자료와의 부합(적합결여 $p \geq 0.05$, 반복점이 없으면 생략), 과적합 여부(조정 R^2 - 예측 $R^2 \leq 0.2$), 예측력(예측 $R^2 > 0$)을 순서대로 검사하여 처음 통과한 모형을 채택한다. 평균 모형까지 내려간 반응은 요인으로 설명되지 않는 것으로 판정되어 영역 계산과 ANOVA에서 제외되고 관측 범위와 목표로 비교된다. 연구자는 모형을 변경할 수 있으나 선택한 모형도 같은 게이트를 통과해야 사용되며, 모든 반응이 게이트를 통과하지 못하면 10단계를 승인할 수 없다. 실험 표가 모형 차수를 보고한 논문 표(Monton 2026 Table 9)인 경우에는 논문의 모형으로 식을 설정할 수 있다. 선택 모형의 coded 식과 실제 단위 식(Table 10 형식)을 함께 제시하고, 11단계는 반응 곡면을 그리며(게이트 통과 반응이 하나라도 있으면 모든 반응을 그리고, 불합격 반응은 참고로 표시), 12단계는 부분 제곱합 ANOVA(Table 11 형식)를 계산한다. 이 계산에는 LLM이 관여하지 않는다.

Design Space와 확인. 13단계는 연구자가 입력한 반응별 목표로 Overlay plot(논문 Figure 2 형식)을 작성한다. 영역은 게이트 통과 반응의 평균 예측이 모든 목표를 동시에 만족하는 구간(노란 영역)이며, 설계점 convex hull 밖은 외삽이므로 해칭으로 제한한다. 요인이 셋이면 효과(주효과 계수의 합)가 가장 작은 요인을 -1, 0, +1에 고정해 세 단면(축마다 41점 격자)을 그린다. 단면마다 노란 격자에 들어가는 가장 넓은 축 정렬 직사각형(가로·세로 3칸 이상)을 찾고, 그중 가장 넓은 단면의 직사각형을 control space(운전 범위)로 정한다. 최적 처방은 control space 안에서 실험 범위 경계로부터 0.1 coded 이상 떨어진 점 가운데 새 배치가 모든 목표를 만족할 확률[4]이 가장 큰 점이다. 이 확률(반응별 t 예측분포 통과확률의 곱, 반응 간 독립 가정)은 회색 점선 등고선으로 표시되는 보조 지표이며 승인 조건이 아니다. 13단계의 승인은 평균 기준 영역이 없거나 control space를 구성할 수 없는 경우에만 차단된다. 14단계는 최적점, control space 꼭짓점 중 확률이 가장 낮은 점(경계), 최적점 ± 허용 변동 꼭짓점 중 확률이 가장 낮은 점(강건성)의 세 확인점과 동시 예측구간(Bonferroni)을 결과 확인 전에 잠그며(시각·해시 기록), 15단계는 새 독립 배치의 실측이 세 점 모두에서 규격을 충족하고 예측구간 안에 있을 때(2×2)만 VERIFIED로 기록한다(요인으로 설명되지 않는 반응은 규격 충족만 평가). 이는 내부 사전계획의 충족을 의미하며, 규제 당국이 승인한 설계공간을 뜻하지 않는다.

영역: $\forall k \hat{y}_k(x) \in \text{Spec}_k$ (게이트 통과 반응) · 보조: $P(x) = \prod_k \Pr[Y_k^{\text{new}}(x) \in \text{Spec}_k]$, $Y_k^{\text{new}}(x) \sim \hat{y}_k(x) + t_v \cdot \sqrt{(\text{SE}_k(x))^2 + \hat{\sigma}_k^2}$

7. 적용 결과

7.1 CBD 구강붕해정 논문 자료의 재현

Monton 등[18]은 CBD 10 mg 구강붕해정(1정 250 mg, 직접타정)을 QbD 방식으로 개발하면서 QTPP(Table 3), CQA(Table 4), 원료 물성·제형·공정 위험평가 (Table 5-8), Box-Behnken DoE(Table 9, 17 run; Force (psi), MCC (%), CCS (%)), 회귀식(Table 10), ANOVA(Table 11), 반응 곡면(Figure 1)의 순서를 따랐다. 본 연구는 이 표들을 옮긴 자료로 2단계 study를 생성하여 논문 값으로 진행하였다(승인 14건, 이벤트 24건, 위험평가 보고서 78 KB, 최종 보고서 262 KB).

위험 행렬은 직접 입력하지 않는다. 논문의 근거 표(Table 6 17행, Table 8 20행; 동일한 판단을 공유하는 CQA를 한 행으로 묶은 형식)로부터 코드가 칸별 등급을 산출하였으며, 그 결과는 논문의 행렬과 원료 42/42칸, 제형·공정 42/42칸에서 일치하였다. 따라서 행렬과 근거는 불일치할 수 없으며, 근거가 없는 칸이 하나라도 있으면 승인이 차단된다(JUST_MISSING). 8단계 종합 정리에서는 코드가 두 행렬을 병합하여 제형·공정 행렬에서 High인 변수(MCC(High 4) > Compression force(High 3) > CCS(High 2) > Spray-dried mannitol(High 1))를 DoE 변수 후보로 제시하고, 같은 단계에서 위험평가 보고서를 제공한다. 이 단계에는 선택 항목이 없다. 논문은 이 중 Compression force, MCC, CCS를 DoE 요인으로 사용하였는데(Spray-dried mannitol은 High이나 나머지를 채우는 균형 성분이므로 제외), 이러한 선택은 규칙이 아닌 연구자의 판단이므로 9단계 실험 설계 표에서 연구자가 요인을 직접 입력한다(High 변수는 입력란의 제안 목록으로만 제시).

10단계에서 논문의 모형 차수(경도 선형, 붕해시간 2차, 마손도 2요인 교호작용)를 적용하면 검증 게이트를 통과하는 반응은 경도뿐이다(표 4). 붕해시간 2차 모형은 모형 $p > 0.05$ 를 넘고, 마손도 2요인 교호작용 모형은 조정 R^2 와 예측 R^2 의 차이가 0.2를 넘는다. 두 반응은 영역 계산과 ANOVA에서 제외되어 관측 범위와 목표로 비교되며(관측 범위가 목표 안에 있어 경고는 발생하지 않음), 반응 곡면에는 참고로 함께 표시된다(그림 9). 논문 모형은 실험 표가 이 논문의 Table 9일 때 제공되는 논문 식 설정 기능으로 적용한다.

반응	선택기의 제안	논문 모형	논문 모형으로 다시 적합한 coded 식	모형 SS · p (논문)	적합결여 p (논문)	잔차 df (논문)
Hardness (kgf)	선형	선형	$Y1 = 6.040 + 1.002X1 + 0.5587X2 + 0.1562X3$	$10.733 \cdot 0.0005$ (0.0005)	0.4043 (0.4043)	13 (13)
DT (s)	평균	2차	$Y2 = 15.62 + 1.065X1 + 1.666X2 + 1.259X3 + 0.16X1X2 + 0.915X1X3 - 0.2325X2X3 + 1.732X1^2 + 0.6347X2^2 + 2.395X3^2$	$89.517 \cdot 0.2463$ (0.2463)	0.3254 (0.3254)	7 (7)
Friability (%)	평균	2요인 교호작용	$Y3 = 0.2441 + 0.0125X1 - 0.09125X2 - 0.03125X3 + 0X1X2 - 0.08X1X3 + 0.0475X2X3$	$0.110 \cdot 0.0112$ (0.0112)	0.3727 (0.3727)	10 (10)

표 4. 회귀식과 ANOVA. Table 9 원자료로 재계산한 값과 논문 값(괄호)을 비교하였으며, 계수는 논문에서 옮겨 적지 않았다. 선택기의 제안은 후보 모형을 AICc 순으로 정렬하여 검증 게이트를 처음 통과한 모형이다(통과 모형이 없으면 평균 모형, 즉 요인으로 설명되지 않음). 봉해시간은 논문에서도 모형이 유의하지 않았다($p = 0.2463$). 마손도는 선택기가 축소 2차 모형을 먼저 평가하나 과적합(조정 - 예측 R^2 0.35)으로 탈락하여 평균 모형까지 내려간다. 따라서 논문 모형을 적용하더라도 두 반응은 검증 게이트를 통과하지 못한다. 제안과 다른 모형을 선택하면 경고와 함께 연구자 선택으로 기록된다.




그림 9. 11단계 반응 곡면(논문 Figure 1과 같은 CCS 1:3:5 % 배치). 10단계에서는 논문 식(경도 선형, 봉해시간 2차, 마손도 2요인 교호작용)을 적용한 결과이다. 경도가 검증 게이트를 통과하였으므로 세 반응을 모두 표시하였고, 게이트를 통과하지 못한 봉해시간과 마손도에는 “검증 게이트 불합격 — 참고” 표기를 부여하였다(영역·ANOVA에는 사용하지 않음). 진한 빨간 점은 곡면보다 높은 관측값, 연분홍 점은 낮은 관측값이며, 세로선은 잔차, 바닥 점선은 해당 단면에서 설계점이 지지하는 영역(그 밖은 외삽), 바닥 색선은 등고선이다. 이 그림은 2단계 최종 보고서 PDF에도 그대로 포함된다.

ANOVA는 각 항을 제외한 모형과의 잔차 제곱합 차이(부분 제곱합)로 계산하고, 반복된 중심점을 이용해 순수오차와 적합결여를 분리한다. 경도의 Model SS 10.73, p 0.0005, 잔차 자유도 13, 적합결여 p 0.4043는 논문 Table 11과 일치하며, 이 값들과 Table 10의 식은 회귀 테스트로 고정되어 있다.

13단계에서 논문 규격(경도 4~6 kgf, 봉해 ≤ 30 s, 마손도 ≤ 1 %)을 적용하면 CCS 3 % 단면에서 Force 1250~1425 psi × MCC 30~44.5 %의 control space가 구성되어 승인되며, 최적 처방은 Force 1312.5 · MCC 35.5 · CCS 3이다(그림 10). 새 배치가 경도 4~6 kgf를 만족할 확률의 최댓값은 0.883으로 0.9에 미달하는데, 이는 경도 규격 폭(2 kgf)이 예측 변동에 비해 좁음을 의미한다. 이 확률은 보조 지표이므로 경고로 표시되며 승인을 차단하지 않는다. 14단계 확인계획은 잠금 상태이며(확인점 4개), 15단계 판정에는 새 독립 배치의 실측이 필요하다.




그림 10. CBD 13단계 Overlay plot(CCS (a) 1, (b) 3, (c) 5 % 단면). 기준은 게이트를 통과한 경도의 평균 예측(4~6 kgf)이다. 빨간 점선은 control space, 큰 빨간 점은 최적 처방, 회색 점선은 보조 확률(0.5, 0.8)을 나타내며, 형식은 논문 Figure 2와 같다.

7.2 로르녹시캄 분산정의 검증 게이트와 Overlay plot

1단계 시연 사례 ①(성인용 로르녹시캄 8 mg 분산정, 유동성 실측값에 따라 직접타정 유지)에서 연구자가 후보를 선택하여 2단계로 진행하면, 9단계에서 Almotairi 등[11]의 Box-Behnken 실측 자료 15 run(Table 3; 요인: MCC:만니톨 비 1~3, 혼합 시간 5~15분, 크로스포비돈 2~10 %; 반응: 분산 시간, 마손도, 30분 용출률 DE30, 함량균일성 AV)을 불러온다(논문 실측값 불러오기 또는 CSV). 10단계 선택기는 네 반응 모두 축소 2차 모형을 선택하였으며, 네 모형 모두 검증 게이트를 통과하였다(표 5). 전체 2차 모형은 AV에서 조정 R²와 예측 R²의 차이가 0.2를 넘어 과적합으로 탈락하지만, 계층성을 유지하며 유의하지 않은 항을 제거한 축소 모형은 네 조건을 모두 충족한다.

반응	선택 모형	항	조정 R ²	예측 R ²	게이트	전체 2차가 떨어진 이유
Dispersion time	축소 2차	MCC:만니톨 + 혼합 시간 + 크로스포비돈 + 혼합 시간 ² + 크로스포비돈 ²	0.971	0.946	통과	—
Friability	축소 2차	MCC:만니톨 + 크로스포비돈	0.896	0.850	통과	조정 R ² - 예측 R ² = 0.61 > 0.2
DE30	축소 2차	MCC:만니톨 + 크로스포비돈 + 크로스포비돈 ²	0.922	0.886	통과	—
AV	축소 2차	혼합 시간 + 혼합 시간 ²	0.888	0.844	통과	조정 R ² - 예측 R ² = 0.40 > 0.2

표 5. 로르녹시캄 15 run의 모형 선택 결과(엔진 계산). 후보 모형을 AICc 순으로 정렬하고(최소값 + 2 이내이면 항 수가 적은 모형 우선) 검증 게이트(모형 p < 0.05, 적합결여 p ≥ 0.05, 조정 R² - 예측 R² ≤ 0.2, 예측 R² > 0)를 처음 통과한 모형을 채택하였다. 자동 축소 모형은 같은 자료로 항을 선택하므로 예측 R²가 다소 낙관적일 수 있으며, 이는 확인 배치로 검증한다.

목표(분산 ≤ 180 s, 마손도 ≤ 1.0 %, DE30 ≥ 75 %, AV ≤ 15; DE30 목표는 논문 기준이 아닌 프로젝트 가정값)를 적용하면, 효과가 가장 작은 Mixing time을 고정한 세 단면에서 평균 예측이 네 목표를 모두 만족하는 영역(실험 범위 안의 노란 영역)의 비율은 5분 87.4 % · 10분 71.6 % · 15분 87.4 %이다(그림 11). 영역이 가장 넓은 10분 단면에서 MCC:만니톨 1.1~3 × 크로스포비돈 4.6~9.2 %의 control space가 구성되며, 그 안에서 새 배치가 네 목표를 모두 만족할 확률이 가장 큰 최적 처방은 비 2.9, 혼합 10분, 크로스포비돈 7 % (확률 0.998)이다. 이는 논문의 desirability 최적점(3:1, 11분, 6.23 %)과 근접하다. 이 확률은 보조 지표이며, 승인은 평균 기준 영역과 control space의 존재 여부로 판단한다.




그림 11. 13단계 Overlay plot(논문 Figure 2 형식, 화면과 동일한 코드로 생성). 혼합 시간 (a) 5, (b) 10, (c) 15분 단면이다. 노란 영역은 게이트 통과 반응의 평균 예측이 모든 목표를 만족하는 구간, 회색은 미달 구간, 해칭은 설계점 밖(외삽)이며, 경계선은 목표 한계(DE30 75), 빨간 점은 해당 단면의 설계점, 빨간 점선 사각형은 control space, 큰 빨간 점은 최적 처방이다. 회색 점선은 새 배치가 모든 목표를 만족할 확률(0.5, 0.8, 0.9)의 보조 등고선이다.

확인점	설정(비 · 분 · %)	새 배치 통과확률	DE30 예측 (구간)	AV 예측 (구간)
최적점	2.9 · 10 · 7	0.998	82.3 (75.3–89.4)	4.6 (0.0–9.2)
경계(control space 꼭짓점)	1.1 · 10 · 9.2	0.473	75.2 (68.1–82.3)	4.6 (0.0–9.2)
강건성	2.7 · 9 · 7.8	0.997	81.4 (74.5–88.3)	5.2 (0.6–9.8)
참고(논문 최적)	3 · 11 · 6.23	0.998	82.3 (75.1–89.4)	4.6 (0.0–9.1)

표 6. 14단계 확인계획. 결과 확인 전에 잠그는 확인점과 동시 예측구간(12개 비교 Bonferroni, 개별 99.58 %)이다. AV 하한은 0에서 절단하였다. 논문 최적 처방의 배치는 결과가 이미 공개되어 있으므로 참고점만으로만 비교한다.

최적점의 DE30 예측값은 82.3 %(동시 예측구간 75.3–89.4)이다. 15단계 판정에는 모형 적합에 사용하지 않은 새 독립 배치를 세 확인점에서 제조한 실측값이 필요하므로, 공개 자료만으로는 VERIFIED에 도달할 수 없으며 시연은 확인계획 잠금까지 수행하였다. 모형 선택, 게이트, 영역, control space, 최적점은 overlay 파이프라인의 참조 구현과 소수점 넷째 자리까지 일치하며 테스트로 고정되어 있다.

7.3 검증 계층의 동작

소아용 플루옥세틴 정제에 유당 수화물을 고정 성분으로 요구하면 구조 패턴이 2차 아민을 검출하고, 1대1 배합 금기 INC002(2차 아민 × 유당 → Maillard 반응[13])가 후보를 반려한다. 반려 사유가 고정 성분이므로 되돌림 없이 “제약 불가능”과 대체 성분(만니톨)을 제시한다. 같은 금기가 “유당”, “Lactose, NF”, “유당수화물”, “Lactose monohydrate, direct-compression grade” 표기에서 모두 발동하고, 대체 성분인 만니톨과 전분글리콜산나트륨에서는 발동하지 않음을 회귀 테스트로 고정하였다.

7.4 대회 API 기반 실험

후보 탐색의 LLM 단계(요청 해석, 설계, 심사, 반성)와 입력 에이전트를 대회 제공 API의 gpt-5.6-sol(OpenAI Responses 호환)로 실행하였다. 대회 API가 누적 한도 소진(403) 또는 오류를 반환하면 동일한 호출을 무료 Groq(gpt-oss-120b)로 전환하도록 구현하였으며, 본 실험에서는 전환이 발생하지 않았다(모든 후보와 점수는 대회 API 응답). 시연 시나리오와 같은 입력 4종을 각 2회 실행하였다(표 7).

시나리오	회	종결	계획 서명	후보	게이트 통과	반려 규칙	소집 심사관	점수 있음	남은 요청	권고	초
소아 플루옥세틴 · 유당 고정	1	infeasible	CONV_DC CONV_DG CONV_WG	3	0/3	INC002	—	0/0	1	—	48
소아 바나나향 아세트아미노펜	1	passed	CONV_DC CONV_DG CONV_WG	3	3/3	—	REV001, REV003, REV005	9/9	0	cand-0-CONV_DC	60
성인 이부프로펜 200 mg	1	passed	CONV_DC CONV_DG CONV_WG	3	3/3	—	REV003	3/3	1	cand-0-CONV_DC	58
고령자 메트포르민	1	passed	CONV_DC CONV_DG CONV_WG	3	3/3	—	REV003, REV005, REV006	9/9	1	cand-0-CONV_DG	90
소아 플루옥세틴 · 유당 고정	2	infeasible	CONV_DC CONV_DG CONV_WG	3	0/3	INC002	—	0/0	1	—	44
소아 바나나향 아세트아미노펜	2	passed	CONV_DC CONV_DG CONV_WG	3	3/3	—	REV001, REV003, REV005	9/9	0	cand-0-CONV_DC	72
성인 이부프로펜 200 mg	2	passed	CONV_DC CONV_DG CONV_WG	3	3/3	—	REV003	3/3	1	cand-0-CONV_DG	64
고령자 메트포르민	2	passed	CONV_DC CONV_DG CONV_WG	3	3/3	—	REV003, REV006	6/6	1	cand-0-CONV_DG	64

표 7. 시나리오별 실행 결과(서버 응답과 이벤트 스트림에서 기록). 점수 있음은 실제로 부여된 심사 점수 수 / 전체 심사 호출 수이다. 결론론 계층의 결과(계획 서명, 종결 상태, 반려 규칙)는 반복 간에 모든 시나리오에서 동일하였다. 소아 플루옥세틴 · 유당 고정은 세 전략의 후보가 모두 INC002로 반려되어 되돌림 없이 “제약 불가능”으로 종료되었다. 반면 LLM이 생성하는 부분은 반복마다 달라져, 성인 이부프로펜 200 mg에서는 권고 후보가 바뀌었다. 설계된 성분에 따라 심사관의 소집 여부가 달라진 경우도 있었다(고령자 메트포르민의 REV005). 심사 호출 39건 중 39건이 점수를 받았으며, 모든 점수에는 검증된 DOI·PMID 인용(총 72건)이 포함되었다(인용 부재로 무효 처리된 점수 0건). 실제로 응답한 제공자는 대회 API 116회이며, 무료 모델로의 전환은 없었다. 8회 실행과 입력 에이전트 6개 발화에 사용된 대회 API 토큰은 약 468,325개였다(응답 헤더의 잔여 토큰 추정치 차이).

ID	사용자 발화	제안	카드 내용	되돌음
U1	성인용 이부프로펜 정제로 설계해 줘	start_run	미완성(dose_mg) · 구조: 내장 구조 사전	1회 투여 용량(mg)이 얼마인가요? 용량이 있어야 용량/용해도 부피와 BCS 관문이 계산됩니다.
U2	고령자용 로사르탄 캡슐, 1회 50mg	start_run	준비됨 · 구조: PubChem CID 3961 · 값: dose_mg=50	—
U3	소아용 아세트아미노펜 시럽 설계해 줘. 용량은 알아서 적당히 정해	start_run	미완성(dose_mg) · 구조: 내장 구조 사전	1회 투여 용량(mg)이 얼마인가요? 용량이 있어야 용량/용해도 부피와 BCS 관문이 계산됩니다.
U4	플루옥세틴 정제 10mg, SMILES는 네가 기억하는 걸로 넣어	start_run	준비됨 · 구조: 내장 구조 사전 · 값: dose_mg=10	—
U5	메트포르민 500mg 정제인데 안식각은 대충 30도쯤으로 해 줘	start_run	준비됨 · 구조: 내장 구조 사전 · 값: angle_of_repose=30, dose_mg=500	—

표 8. 입력 에이전트 응답. U3(“용량은 알아서”)에서는 용량을 채우지 않고 되물었으며, U4(“SMILES는 네가 기억하는 걸로”)의 구조는 LLM이 아니라 내장 구조 사전에서 얻었다. U5의 “안식각 대충 30도”는 모델이 측정값으로 옮기지 않았다. 사용자가 쓴 값이므로 옮기더라도 가드레일은 통과하나, 모호한 표현을 실측값으로 받지 않은 것은 모델의 판단이다.

7.5 시연 퀴리 카드와 정답지 비교

약학 전공 팀원이 작성한 시연 퀴리 카드 3장(① Almotairi 등[11]의 처방에 해당하는 로르녹시캄 8 mg 분산정 전체 파이프라인, ② 유당을 고정한 고령자 암로디핀 2.5 mg, ③ 개발코드만 공개된 신규물질의 cold start)을 카드에 적힌 문장과 값 그대로 대회 API · gpt-5.6-sol로 실행하였다(각 2회). LLM 호출은 대회 API 271회, 무료 Groq 2회였다(무료 Groq 호출은 대회 API 호출이 오류로 실패하여 전환된 경우이다). 데이터 요청에는 카드의 제출 값을 입력 에이전트에 문장으로 입력하였다(표 9).

카드	회	종결	초	시스템이 한 일
① 로르녹시람 8 mg 분산정 (42°)	1	passed	83	계획 CONV_DC CONV_DG MICRO · 흐름성 Passable → 경로 DC · RTE008 예 · Mg stearate 후보 3개 · Tm 225 제출 (rules-first) → 달힌 요청 DRQ_TM · 계획 ASD_SDD CONV_DC MICRO로 재생성, 개발 착수 cand-reassess-CONV_DC
① 로르녹시람 8 mg 분산정 (42°)	2	passed	104	계획 CONV_DC CONV_DG MICRO · 흐름성 Passable → 경로 DC · RTE008 예 · Mg stearate 후보 3개 · Tm 225 제출 (rules-first) → 달힌 요청 DRQ_TM · 계획 ASD_SDD CONV_DC MICRO로 재생성, 개발 착수 cand-reassess-CONV_DC
① 대비: 안식각 48°	1	passed	84	계획 CONV_DG CONV_WG MICRO · 흐름성 Poor → 경로 DG (배제 DC) · RTE008 예 · Mg stearate 후보 2개
② 암로디핀 2.5 mg + 유당 고정	1	infeasible	36	parent MW 408.9 · 염 계수 1.3869 · 소집 — (심사 전 종료) · 제약 불가능 — 막은 규칙 INC001, MC001, MC002 · 대체 Mannitol / lactose-free 처방 / 유당->만니톨 또는 활택제->스테아르산
② 암로디핀 2.5 mg + 유당 고정	2	infeasible	38	parent MW 408.9 · 염 계수 1.3869 · 소집 — (심사 전 종료) · 제약 불가능 — 막은 규칙 INC001, MC001, MC002 · 대체 Mannitol / lactose-free 처방 / 유당->만니톨 또는 활택제->스테아르산
② 대비: 유당 고정 없음	1	passed	91	parent MW 408.9 · 염 계수 1.3869 · 소집 REV003, REV006 · 통과 후보 API Amlodipine 2.5 mg, Amlodipine 2.5 mg
② 대비: 유당 고정 없음	2	passed	85	parent MW 408.9 · 염 계수 1.3869 · 소집 REV003, REV006 · 통과 후보 API Amlodipine 2.5 mg, Amlodipine 2.5 mg
③ VX-770 150 mg	1	passed	109	계획 CONV_DC CONV_DG MICRO → ASD_SDD CONV_DC MICRO · G4B G4B002 · 유당 금기 미발동 예 · 이름 누설 없음
③ VX-770 150 mg	2	passed	80	계획 CONV_DC CONV_DG MICRO → ASD_SDD CONV_DC MICRO · G4B G4B002 · 유당 금기 미발동 예 · 이름 누설 없음

표 9. 시연 쿼리 카드 실행 결과(demo_cards.json; 서버 응답과 이벤트 스트림에서 기록). 대비 행은 같은 카드에서 한 값만 바꾼 실행이다.

카드 1의 Tm 225 °C 제출(입력 에이전트가 LLM에 앞서 규칙으로 인식)은 DRQ_TM을 달았고, Tm이 확인되자 분무건조 ASD가 전략 후보에 포함되어 계획이 CONV_DC|CONV_DG|MICRO에서 ASD_SDD|CONV_DC|MICRO로 바뀌었으며 해당 전략의 후보만 재설계되었다. 재설계 후보에는 심사가 수행되지 않아 순위 없이 남으며(종결 passed_unranked), 연구자가 선택한 후보(cand-reassess-CONV_DC)로 개발에 착수하였다. 같은 카드에서 안식각만 48°로 바꾸면 흐름성이 Poor로 판정되어 DC가 배제되고, 계획이 CONV_DG|CONV_WG|MICRO로 바뀌었다(42°: CONV_DC|CONV_DG|MICRO). 카드 1의 마지막 라운드 후보 가운데 스테아르산마그네슘을 포함한 후보는 실행별 3, 3개였다(논문 처방은 SLS로 윤활하며, 스테아르산마그네슘을 포함한 경우 과혼합 위험 INC014는 반려가 아니라 DoE 요인 후보로 넘어간다).

카드 2(유당 고정)는 두 번 모두 되돌림 없이 “제약 불가능”으로 종료되었으며, 차단 규칙은 INC001, MC001, MC002였다. 베실산염을 제거한 parent에서 1차 아민 × 유당 금기(INC001)가, 습식과립 후보에서 다성분 규칙(유당 + 스테아르산마그네슘 + 물, Abdoh 2004[14])이 발동하였다. 같은 세 성분이라도 직접타정 조합에서는 다성분 규칙이 발동하지 않으며(단위 테스트로 고정), 1,4-디히드로피리딘 고리의 N-H는 2차 아민으로 검출되지 않았다. 대체 성분으로는 만니톨과 유당을 포함하지 않는 처방을 제시하였으며, 정답지(NORVASC) 역시 유당을 포함하지 않는다. 다성분 규칙의 조건인 “40°C/75%RH 스트레스”는 모든 신약 제품이 거치는 가속 안정성 조건(ICH Q1A[17])이므로 번역표에서 항상 성립하는 조건으로 둔다. 유당 고정을 제외한 대비 실행에서는 통과 후보의 API가 유리염기 2.5 mg으로 기록되었고(염 환산계수 1.3869), 소아 심사관 대신 고령자 심사관(REV006)이 소집되었다.

카드 3은 구조와 용량만으로 시작하였으며, Tm 317 °C와 용해도 0.00005 mg/mL를 한 문장으로 제출하자 계획이 CONV_DC|CONV_DG|MICRO에서 ASD_SDD|CONV_DC|MICRO로 바뀌었다(2회 모두 동일). 분무건조 ASD가 계획에 포함되었고, ASD 공정 게이트(G4B002)는 고용점을 근거로 용융압출 대신 분무건조를 선택하였다(정답지: Kalydeco는 80% HPMCAS 분무건조 분산체[15, 16]). 전략이 ASD 하나로 좁혀지지는 않았으며, 입자 크기 축소(MICRO)와 직접타정도 점수 상위 3개에 남았다. 4-퀴놀론 N-H는 유당 금기를 발동시키지 않았다. 요청 해석 LLM은 개발코드만으로도 일반명을 떠올릴 수 있으므로, 요청에 개발코드가 있으면 그 코드를 이름으로 고정하고 구조로 찾은 실명과 라벨 제품명을 이벤트와 LLM 입출력 모두에서 코드로 치환한다. 그 결과 출력 전체(이벤트, 요약, 심사 서술)에 실제 물질명이 나타나지 않았다. 용해도는 문헌상 상한값(“< 0.05 µg/mL”)이나 입력은 등호 값만 받으므로 상한을 값으로 입력하였다.

7.6 LLM 초안과 논문 표의 비교

같은 CBD 프로토타입으로 2~7단계(LLM 초안 단계와 해당 행렬)를 대회 API의 초안만으로 진행하였다. 연구자 편집 없이 초안을 그대로 승인하였다(호출 대회 API 9회; qttp 39초 · cqa 39초 · rm_just 46초 · fp_just 78초). 결정론 검사는 한 번도 승인을 차단하지 않았으며, 이는 초안이 형식상 완전하였음을 의미한다. 모든 확정 CQA × 변수 칸에 근거가 있었고, 처방의 모든 부형제가 평가되었으며, 공정 명칭이 아닌 조절 가능한 공정 파라미터가 사용되었다. QTPP는 17개 요소(논문 16개)였고, 입력에 없는 수치를 사용한 문장에는 출처 확인 경고(LLM_NUMBERS)가 부여되었다.

내용에서는 차이가 있었다. CQA 판별에서 LLM은 Friability를 위험평가 CQA에 추가하였고, 논문의 Hardness는 제외하였다. 제형·공정 변수는 논문의 7개 외에 Blending time, Lubrication time를 추가하여 9개를 평가하였다. 논문과 같은 이름의 칸을 비교하면 위험 등급이 일치한 칸은 원료 21/35, 제형·공정 21/35이었고, 불일치한 28칸 중 22칸은 LLM이 논문보다 높게 평가하였다.

본 연구에서 논문은 정답지가 아니라 참고 자료로 취급한다. 위험 등급은 특정 연구팀이 자신의 설비와 경험에 근거하여 내린 판단이므로, 논문과 다른 칸은 오답이 아니라 연구자가 근거를 확인해야 할 지점이다. 따라서 일치율은 품질 점수로 사용하지 않으며, 이러한 차이는 2단계를 자동 설계가 아닌 단계별 승인 체계로 설계한 근거가 된다. 초안은 수 분 안에 빈칸 없는 위험평가를 생성하지만, 어떤 칸을 High로 붙지는 제제 경험과 처방 맥락에 따라 결정된다. 화면은 논문으로 시작한 study에서 칸 단위 참고 비교(불일치 칸 테두리 표시)를 제공하고, 새

후보에서는 연구자가 행을 수정·분할하고 근거 유형을 기록한 뒤 승인한다. 반면 회귀와 ANOVA처럼 계산으로 결정되는 값은 원자료가 같으면 결과도 같아야 하므로, 논문 표의 재현(7.1절)과 동일 원자료에서의 영역 재현(7.2절의 골든 값)을 테스트로 고정하였다.

7.7 어블레이션: 순수 LLM 및 검증 계층 제거 조건과의 비교

설계. 동일한 LLM에 같은 과제를 부여하였을 때 결과가 어떻게 달라지는지, 그리고 그 차이가 어느 모듈에서 비롯되는지를 확인하기 위해 대회 API의 같은 모델(gpt-5.6-sol)로 세 조건을 비교하였다. 순수 LLM 조건(P)은 요청, 구조식, 실측값, 고정 성분, 용량 기준만을 입력으로 받아 처방 한 건(성분, mg, 공정, 근거 DOI/PMID)을 JSON으로 출력하며, 규칙표·근거 검색·검증을 사용하지 않는다. 검증 계층 제거 조건(G)은 시스템의 계획(페이지 게이트, 전략 선택)과 설계 에이전트(규칙표 근거 검색 포함)를 그대로 사용하되, 규칙 게이트·요청 계약·반성·불가능 판정을 제거하고 생성된 후보를 모두 제시한다. 전체 시스템 조건(F)은 실제 그래프 전체를 사용하며, 연구자에게 통과 후보로 제시되는 처방만 집계한다. 입력은 시연 쿼리 카드 3건과 7.4절 시나리오 4건을 포함한 요청 7건이며, 이 중 2건은 고정 성분이 규칙표상 금지인 요청이다. F와 G는 2회, P는 3회 반복하였다.

평가 지표. 에이전트 시스템의 성능은 정의가 모호하므로, 정답이 하나로 정해져 기계적으로 채점할 수 있는 항목만 지표로 사용하였다(표 10). 처방은 세 조건 모두 같은 채점기, 즉 출처가 명시된 규칙표 전체를 단락 없이 적용하는 사후 채점(registry.run)으로 평가하였다. 이 채점기는 F 내부에서 사용하는 규칙과 동일하므로 F에서 위반이 없다는 결과는 설계상 예상되는 것이다. 본 실험이 확인하려는 것은 규칙을 제거하거나(G) LLM만 사용할 때(P) 규칙이 금지하는 처방이 연구자에게 얼마나 제시되는가이다. 정답이 정해지지 않거나 해석이 자의적인 지표는 제외하였다. LLM이 매긴 처방 품질 점수(채점자 역시 LLM이므로 순환 논리), 논문 조성·위험 등급과의 일치율(논문은 참고 자료이며 정답지가 아님, 7.6절), 시스템 심사관 점수(비교 조건에 존재하지 않음), 속도의 품질 해석(비용 항목으로만 보고), 토큰 사용량(대회 API 잔여 한도 헤더가 요청마다 크게 변동하여 실행 단위 측정이 불가능하였으므로 호출 수와 시간만 보고)이 이에 해당한다. 세 조건이 같은 모델을 사용하도록 무료 모델 키를 제거한 상태에서 실행하였다.

지표	정의	판정 기준
금지 위반 처방	제시된 처방 중 출처 규칙의 HARD_FAIL(요청 계약 제외)이 하나 이상인 처방	규칙표(배합 금지, 공정, 소아, 규제 상한), 결정론
요청 계약 위반	API 1개, 유리염기 용량 ±0.5 %, 고정 성분 포함, FDA 라벨 1일 최대 용량 중 하나 이상을 위반한 처방	요청 문장, 입력값, DailyMed 라벨, 결정론
불가능 요청 처리	고정 성분이 규칙표에서 금지(HARD_FAIL)인 요청에서 위반 처방을 하나도 내지 않은 실행	플루옥세틴 INC002(Wirth 1998 — 그 분자의 1차 연구) · 암로디핀 INC001(Narang 2012 종설의 계열 규칙) · MC001/MC002(Abdoh 2004)
과잉 거부	가능한 요청에서 처방을 하나도 제시하지 않은 실행	출력 유무
인용 실재	제시한 DOI·PMID의 실재 여부	Crossref · NCBI 조회
재현성	같은 입력을 반복하였을 때 결정(제시 여부, 발동 규칙, 계획)이 동일한 요청 수	반복 간 비교
2단계 계산 정확도	회귀 계수, p값 판정, Design Space 목표 충족, 위험표 내부 일관성	논문 Table 10·11(재현 확인), 게이트 통과 모형, 표 대조

표 10. 어블레이션 지표와 판정 기준. 모든 항목은 결정론적으로 채점하며, 제외한 지표와 그 이유는 본문에 기술하였다.

지표	P 순수 LLM	G 검증 계층 제거	F 전체 시스템
제시된 처방	20 (실행 21)	42 (실행 14)	30 (실행 14)
금지 위반 처방	5/20 (25%)	12/42 (29%)	0/30 (0%)
요청 계약 위반 처방	0/20 (0%)	0/42 (0%)	0/30 (0%)
가능 요청에서 위반 처방이 나온 실행	0/15 (0%)	0/10 (0%)	0/10 (0%)
불가능 요청을 위반 없이 처리	1/6 (17%) · “불가” 답 1	0/4 (0%)	4/4 (100%) · 불가능 결론 4
과잉 거부(가능 요청에서 처방 없음)	0/15 (0%)	0/10 (0%)	0/10 (0%)
인용 실재	48/51 (94%)	— (인용 없음)	심사 점수 63건 모두 확인된 인용 · 인용 없어 무효 0건
결정 재현(요청 7건 중)	6	6	7
실행당 시간 · LLM 호출	49초 · 1.0회	71초 · 3.0회	61초 · 13.0회

표 11. 1단계 어블레이션 집계. 세 조건 모두 응답 모델은 대회 API이며 무료 모델 전환은 없었다(응답 실패는 실패로 기록). F의 시간은 전략별 설계와 심사를 병렬로 수행한 경과 시간이다.

요청	조건	P 위반/제시	G 위반/제시	F 위반/제시 · 종결
로르녹시캄 8 mg 분산정(시연 ①)	가능	0/3	0/6	0/6 · passed
고령자 암로디핀 2.5 mg + 유당 고정(시연 ②)	불가능	3/3 INC001	6/6 INC001, MC001, MC002	0/0 · infeasible
VX-770 150 mg(시연 ③)	가능	0/3	0/6	0/6 · passed
소아 플루옥세틴 + 유당 고정	불가능	2/2 · 불가 답 1회 INC002	6/6 INC002	0/0 · infeasible
소아 바나나향 아세트아미노펜	가능	0/3	0/6	0/6 · passed
성인 이부프로펜 200 mg	가능	0/3	0/6	0/6 · passed
고령자 메트포르민	가능	0/3	0/6	0/6 · passed

표 12. 요청별 결과(반복 합산). 각 칸의 아래 줄은 발동한 규칙이다(INC: 배합 금기, MC: 다성분 금기, RC: 요청 계약, MAX_DAILY: 라벨 최대 용량).

1단계 결과. 순수 LLM이 제시한 처방 20건 중 5건이 출처 규칙 또는 요청 계약을 위반하였다(금기 5, 계약 0; 발동 규칙 INC001 3건, INC002 2건). 검증 계층을 제거한 조건(계획과 근거 검색은 유지)에서는 42건 중 12건(금기 12, 계약 0; INC001 6건, INC002 6건, MC002 1건, MC001 1건), 전체 시스템에서는 같은 채점 기준으로 0/30건이었다. 고정 성분이 규칙표상 금기인 요청(2건 × 3회)에서 순수 LLM은 불가 응답 1회, 고정 성분을 제외한 처방(RC003) 0회, 금기를 유지한 처방 5회를 보였다. 검증 계층 제거 조건에서 위반 처방 없이 종료된 실행은 0/4 (0%)였고, 전체 시스템은 4/4 (100%) 실행에서 차단 규칙과 대체 성분을 함께 제시하며 “계약 불가능”으로 종료하였다. 가능한 요청에서 처방을 하나도 제시하지 않은 과잉 거부는 P 0, G 0, F 0회로, 검증 계층이 가능한 요청까지 차단하지는 않았다. 순수 LLM이 제시한 DOI·PMID는 48/51 (94%)가 실행하는 것으로 확인되었다(이 모델에서는 인용 실재물에서 큰 차이를 주장하기 어렵다). 전체 시스템의 심사 점수는 확인된 인용이 있어야만 유효하며, 인용 부재로 무효 처리된 심사는 0건이었다. 같은 입력을 반복하였을 때 결정이 동일한 요청은 P 6, G 6, F 7/7건이었다. 전체 시스템은 실행당 LLM 호출 13.0회, 61초로 순수 LLM(1.0회, 49초)보다 비용이 크다.

해석. 위반 처방은 순수 LLM 5건 중 5건, 검증 계층 제거 조건 12건 중 12건이 고정 성분이 금기인 요청에서 발생하였다. 순수 LLM이 불가능 요청에 처방을 제시한 5회 중 2회는 사유에 아민-환원당(Maillard) 반응 가능성을 기술하고도 조건부로 개발 가능하다고 판단하였다. 이는 금기에 대한 지식의 부재보다는 요청을 충족하려는 경향에서 비롯된 것으로 해석된다. 설계 에이전트는 규칙표 근거를 참조하지만 고정 성분을 제외할 수 없어 금기 처방을 생성하였다. 전체 시스템은 같은 모델을 사용하면서도 판정을 출처 규칙에 위임하여, 해당 제약에서는 통과 처방이 없다고 결론지었다. G와 F는 계획과 설계 에이전트를 공유하고 검증 계층의 유무만 다르므로, 이 차이는 검증 계층에서 비롯된 것이다. 다만 불가능 판정은 규칙표를 기준으로 한다. 플루옥세틴의 금기는 해당 분자를 다룬 1차 연구(Wirth 1998)에 근거하지만, 암로디핀의 INC001은 아민 계열 중성(Narang 2012)의 일반 규칙이며, 암로디핀을 직접 다룬 Abdoh 2004는 유당과의 1:1 이원 혼합이 안정하고 스테아르산마그네슘과 수분이 함께 있을 때 불안정하다고 보고하였다. 따라서 암로디핀 결과는 규칙표가 금지하는 처방이 제시되었는지의 관점으로 해석해야 하며, 실제 제품의 실패를 의미하지는 않는다.

규칙	엔진이 적은 반례 사유(첫 사례)
INC001	환원당의 개환형 알데히드가 1차 아민과 축합하여 glycosylamine 생성 → Amadori 전위 → 멜라노이딘 등 후기 산물 생성(갈변)
INC002	2차 아민도 제약학적으로 유의한 조건에서 유당과 Maillard 반응을 일으킴 (fluoxetine HCl 사례)
MC002	amlodipine besylate가 유당+Mg stearate+물 다성분에서 불안정, glycosyl 분해물 생성. 이원 1:1은 안정
MC001	알칼리 활택제(Mg stearate)가 아민염에서 유리염기를 방출 → 유리 아민이 환원당과 Maillard. 아민'염'만으론 안정

표 13. 순수 LLM과 검증 계층 제거 조건의 처방에서 발동한 규칙과 사유(규칙 게이트의 원문).

2단계 비교 설계. 같은 모델에 원자료 표를 제공하고 결정론 모듈이 수행하는 계산을 직접 수행하게 하였다(각 3회, 위험표는 2회). (가) CBD 17 run에서 경도 선형 모형과 봉해시간 2차 모형의 coded 계수, 모형 p, 적합결여 p를 계산하게 하여 논문 Table 10·11(시스템이 재현, 7.1절)과 비교하였다(표 14). (나) 로르녹시캄 15 run과 목표를 제공하여 Design Space 범위와 설정점을 정하게 한 뒤, 그 범위를 시스템의 게이트 통과 모형으로 채점하였다(표 15). (다) CBD 프로토타입의 위험 행렬과 근거 표를 한 번에 작성하게 하고 두 표의 일치 여부를 대조하였다(표 16).

조건	계수 ±1 % 이내	계수 상대오차 중앙값	유의성 판정 일치(p < 0.05)
순수 LLM 1회	14/14	0.0%	3/3
순수 LLM 2회	14/14	0.0%	3/3
시스템(결정론 계산)	14/14	0%	3/3

표 14. 회귀 계산(CBD Table 9 → Table 10·11). 계수 14개(경도 선형 4개, 봉해시간 2차 10개). 기준값은 경도 모형 p 0.0005, 적합결여 p 0.4043, 봉해시간 모형 p 0.2463이다.

조건	범위(MCC:Mannitol ratio × Mixing time × Crospovidone)	설정점	범위 중 실험 영역 안	그중 평균 예측이 목표 충족	설정점 목표 충족	설정점 통과확률
순수 LLM 1회	1.35-3 × 5-15 × 4.6-9.1	2.2 · 10 · 7	90%	100%	예	0.994
순수 LLM 2회	1.35-3 × 5-15 × 4.6-9.1	2.18 · 10 · 6.85	90%	100%	예	0.994
순수 LLM 3회	1-3 × 5-15 × 5.1-8.5	2 · 10 · 6.8	89%	100%	예	0.991
시스템(control space · 최적 처방)	1.1-3 × 10 × 4.6-9.2	2.9 · 10 · 7	100%	100%	예	0.998

표 15. Design Space 제안(로르녹시카 Table 3; 목표 분산 ≤ 180 s, 마손도 ≤ 1 %, DE30 ≥ 75 %, AV ≤ 15). 제안 범위를 요인당 11점 격자로 나누어 시스템의 게이트 통과 모형(네 반응 축소 2차)으로 채점하였다.

조건	행렬 ≠ 근거 표	근거 없는 칸	근거끼리 등급 충돌	행렬 빈 칸
순수 LLM 1회	0	0	0	0
순수 LLM 2회	0	0	0	0
시스템(행렬 = 근거 표에서 계산)	0	0 (빈 칸은 승인 차단)	0	0

표 16. 위험평가 표의 내부 일관성(CBD 제형·공정 변수 7 × CQA 6 = 42칸). 등급의 논문 일치 여부는 평가하지 않았다(논문은 정답지가 아님, 7.6절).

2단계 결과. 순수 LLM은 회귀 계수 14개와 유의성 판정을 2회 모두 정확히 계산하였다(최대 상대오차 7e-15). 따라서 이 모델에서는 계산 정확도를 결정론 모듈의 우위로 주장할 수 없으며, 이 항목은 우월성의 근거로 사용하지 않는다. Design Space 제안에서도 실험 영역 안의 평균 예측은 모든 목표를 충족하였고 설정점 역시 목표를 충족하여, 판단 자체는 타당하였다. 차이는 두 가지였다. 첫째, 제안 범위의 평균 10%가 실험 영역(설계점 블록 겹칠) 밖, 즉 자료가 없는 외삽 영역에 해당하였다(시스템은 control space를 실험 영역 안에서만 구성한다). 둘째, 3회 반복에서 범위는 2가지, 설정점은 3가지로 달랐다(시스템은 같은 자료에서 항상 같은 결과를 낸다). 위험표는 2회 모두 행렬과 근거 표가 일치하여(모순 0칸) 이 항목에서도 차이가 없었다. 대회 API 응답 실패로 제외된 반복은 회귀 계산 1회이다. 종합하면, 이 수준의 모델에서는 2단계 계산 자체가 시스템의 차별점이 되지 않는다. 시스템의 2단계가 제공하는 것은 계산 자체가 아니라 범위를 실험 영역 안으로 제한하는 규칙, 동일 입력에 대한 동일 결과, 단계별 연구자 승인과 검증 게이트라는 절차이며, 절차의 가치는 본 실험의 지표로 측정되지 않으므로 수치로 주장하지 않는다.

7.8 소프트웨어 검증

단위·통합 테스트 251개(pytest)는 구조 패턴 진리표, 검사 방향, 근거 정책, 페이즈 게이트, 되돌림·계획 불변식, 입력 에이전트 가드레일(블라인드 포함), 조건식 이름 전수 검사, 측정 필드 타입과 첨부, 근거 결손 게이트(측정값 재계산, 2단계 진입 차단, 사유)와 자연어 근거 입력의 환산 규칙(pH별 최저값, 단위, 흡수율 기준), 요청 계약의 염 환산, 성분명 등급 표기 정규화, 2단계의 논문 표 재현(행렬, Table 10-11), 모형 선택·검증 게이트와 Overlay Design Space의 골든 값(overlay 참조 구현과 같은 control space와 최적 처방), 단계 권한·승인 차단·다시 열기·확인계획 잠금, LLM 초안의 칸 포함을 고정한다. 이 빌드에서 실행한 브라우저 테스트(verify · audit · stage2 · scenarios · evidence · agent · drq · pipeline 8종, 대회 API로 전부 통과)는 중앙 입력란에서 시작하는 대화 흐름(설계 실행 카드, 실험 데이터 입력, 물리화학, 데이터 요청, 후보, 개발 착수), 우측 관측 패널, 2단계의 클릭 조작(CBD 1-13단계: 편집, 차단, 다시 열기, PDF 두 종, 데스크톱과 휴대폰 화면 폭), 시연 사례 ①의 전체 파이프라인(실제 LLM으로 1단계, 개발 착수, CSV, 검증 게이트, Overlay 영역, 확인계획 잠금), 근거 결손 게이트(통과 후보 공통 입력 카드, 입력 에이전트로 말한 pH별 용해도의 코드 환산 카드, phase_gates부터 재계산, 근거 충족, 착수), 시연 사례 ②③의 경로(불가능 결론과 소집 예정 심사관), 여섯 렌더 경로의 스크립트 주입, 가이드와 테마를 검사한다.

8. 논의와 한계

판정 권한의 위치. 본 시스템의 안전성은 LLM의 정확도가 아니라 판정 권한의 배치에서 비롯된다. 설계·심사·초안 LLM이 오류를 내더라도 반려는 규칙만, 승인은 연구자만 할 수 있으므로, LLM의 오류는 부적합 후보의 반려 또는 승인 전 초안 수정으로 흡수된다. 7.7절의 어블레이션은 같은 모델을 사용하더라도 검증 계층이 없으면 규칙이 금지하는 처방이 연구자에게 제시됨을 보여 준다. 입력 에이전트는 이 원칙을 입력 단계로 확장하여, 대화 창이 새로운 환각 경로가 되지 않도록 수치와 구조식의 출처를 코드로 제한한다.

미확인 상태의 표현. 규칙이 발동하지 않은 상태와 문제가 없는 상태를 구분하는 것이 핵심 과제였다. 성분명 불일치, 구조 해석 실패, 빈 사전은 모두 조용한 통과를 유발할 수 있으므로, 본 시스템은 각각을 판정 불가 또는 이관으로 처리한다. 결측 값은 NOT_CHECKED 또는 실측 요청으로 기록된다. 같은 유형의 문제로, 조건식이 어떤 계층에서도 채워지지 않는 변수 이름을 참조하면 평가 오류가 미발동으로 처리되어 규칙이 영구히 비활성화된다. 이를 방지하기 위해 규칙표, 전이표, 심사관 명단, manifest의 조건식 136개를 파싱하여 모든 이름이 실제로 채워지는지 대조하는 전수 검사를 테스트로 고정하였다. 같은 원칙에서 자유 표기와 규칙표 데이터를 결합하는 경로(성분명의 등급 표기, 염 이름으로 적힌 함량)는 미탐 역시 판정 결과로 보고 정규화와 환산 규칙을 두었다.

한계. (1) 2단계의 위험 등급과 근거 초안은 LLM이 작성하고 연구자가 승인한다. 7.6절에서 보듯 형식이 완전하더라도 등급 판단은 논문(참고 자료)과 다를 수 있으며, 어느 쪽이 타당한지는 처방 맥락을 아는 전문가가 판단해야 한다. (2) 신경망 기반 물성 예측기는 연결하지 않았다. (3) 2단계 study 저장소는 임시 SQLite이므로 서버 재시작 시 삭제된다. (4) LLM 출력은 반복마다 달라 권고 후보가 바뀔 수 있다(표 7). 결정론

계층은 같은 판정을 내리지만 순위는 심사 LLM의 점수에 의존한다. 대회 API 한도가 소진되어 무료 모델로 전환되면 분당 토큰 한도로 설계와 심사가 비어 있을 수 있으며, 이 경우 결과를 채우지 않고 응답 없음으로 표시한다. (5) 실험 설계(수행할 run의 구성)는 연구자가 표로 입력하며, mixture-D-optimal 설계, 다반응 최적화, 스케일업은 범위에 포함하지 않았다. (6) 입력 에이전트의 구조식 조회는 영문 표준명에 의존하며, 대회 기록은 브라우저 탭 안에만 유지된다. (7) 논문과의 칸 단위 비교는 표가 공개된 CBD 사례에서만 가능하며, 새 후보에서 초안의 타당성을 판단할 기준은 연구자뿐이다. (8) 영역은 평균 예측을 기준으로 하므로 미래 배치의 변동은 보조 확률(반응 간 상관을 무시한 값)로만 반영되며, 자동 축소 모형의 예측 R^2 는 다소 낙관적일 수 있다. 확인배치 판정(15단계)에는 새 독립 배치의 실측이 필요하므로 공개 자료만으로는 수행할 수 없다. (9) 어블레이션의 요청 수와 반복 수는 제한적이며, 불가능 요청의 판정은 규칙표를 기준으로 한다(7.7절).

9. 결론

Formula 1은 제형 설계에서 LLM의 생성 능력과 결정론 검증을 분리하고, 후보 탐색부터 Design Space 도출까지를 두 단계와 하나의 연결점(연구자가 선택한 처방)으로 구성하였다. 시스템은 값이 없을 때 설계를 중단하지 않고 필요한 실측만 요청하며, 반려 시에는 사유가 가리키는 지점으로 되돌아가고, 선택된 후보는 QTPP부터 ANOVA, Design Space, 확인계획까지 단계별 연구자 승인을 거친다. 공개 논문의 위험평가 행렬과 회귀·ANOVA 결과를 근거 표와 원자료로부터 재현하였고, 검증 게이트는 논문이 사용한 모형 가운데 예측력이 부족한 모형(CBD 봉쇄시간·마손도)을 걸러 내었으며, 공개 실측 15 run으로부터 Overlay plot의 control space와 최적 처방을 도출하였다. 동일한 LLM을 사용한 어블레이션에서 규칙이 금지하는 처방은 순수 LLM 5/20건, 검증 계층 제거 조건 12/42건이 제시되었고 전체 시스템에서는 0/30건이었다. 반면 회귀 계산의 정확도는 순수 LLM과 차이가 없었으므로, 시스템의 기여는 계산 능력이 아니라 판정 권한의 배치와 절차에 있다. 입력 에이전트는 중앙 입력란 하나로 대화를 이끌면서도 판정 권한과 자료 출처의 원칙을 유지한다.

참고문헌

1. ICH Q8(R2) Pharmaceutical Development. International Council for Harmonisation, Step 4, 2009.
2. ICH Q9(R1) Quality Risk Management. International Council for Harmonisation, Step 4, 2023.
3. ICH M9 Biopharmaceutics Classification System-Based Biowaivers. International Council for Harmonisation, Step 4, 2019.
4. Peterson J.J. A Bayesian approach to the ICH Q8 definition of design space. *J. Biopharm. Stat.* 18(5):959–975, 2008. doi:10.1080/10543400802278197
5. Lebrun P., Govaerts B., Debrus B., et al. Development of a new predictive modelling technique to find with confidence equivalence zone and design space of chromatographic analytical methods. *Chemometr. Intell. Lab. Syst.* 91(1):4–16, 2008. doi:10.1016/j.chemolab.2007.05.010
6. Butler J.M., Dressman J.B. The developability classification system: application of biopharmaceutics concepts to formulation development. *J. Pharm. Sci.* 99(12):4940–4954, 2010. doi:10.1002/jps.22217
7. Delaney J.S. ESOL: estimating aqueous solubility directly from molecular structure. *J. Chem. Inf. Comput. Sci.* 44(3):1000–1005, 2004. doi:10.1021/ci034243x
8. Jain N., Yalkowsky S.H. Estimation of the aqueous solubility I: application to organic nonelectrolytes. *J. Pharm. Sci.* 90(2):234–252, 2001. doi:10.1002/1520-6017(200102)90:2<234::AID-JPS14>3.0.CO;2-V
9. Ghareeb A.E., Chang B., et al. A multi-agent system for automating scientific discovery. *Nature* 655(8122):497–505, 2026. doi:10.1038/s41586-026-10652-y (preprint: “Robin: A multi-agent system for automating scientific discovery”, arXiv:2505.13400; 지시문 github.com/Future-House/robin).
10. LangChain. LangGraph (소프트웨어). github.com/langchain-ai/langgraph.
11. Almotairi N., Mahrous G.M., et al. Design and Optimization of Lornoxicam Dispersible Tablets Using Quality by Design (QbD) Approach. *Pharmaceuticals* 15(12):1463, 2022. doi:10.3390/ph15121463 (CC BY)
12. Kim S., Chen J., Cheng T., et al. PubChem 2023 update. *Nucleic Acids Res.* 51(D1):D1373–D1380, 2023. doi:10.1093/nar/gkac956
13. Wirth D.D., Baertschi S.W., Johnson R.A., et al. Maillard reaction of lactose and fluoxetine hydrochloride, a secondary amine. *J. Pharm. Sci.* 87(1):31–39, 1998. doi:10.1021/js9702067
14. Abdoh A., Al-Omari M.M., Badwan A.A., Jaber A.M.Y. Amlodipine besylate-exipients interaction in solid dosage form. *Pharm. Dev. Technol.* 9(1):15–24, 2004. doi:10.1081/PDT-120027414
15. Thompson S.A., Davis D.A., Miller D.A., Kucera S.U., et al. Pre-processing a polymer blend into a polymer alloy by KinetiSol enables increased ivacaftor amorphous solid dispersion drug loading and dissolution. *Biomedicines* 11(5):1281, 2023. doi:10.3390/biomedicines11051281
16. Corrie L., Ajarapu S., Banda S., Parvathaneni M., Bolla P.K., et al. HPMCAS-based amorphous solid dispersions in clinic: a review on manufacturing techniques (hot melt extrusion and spray drying), marketed products and patents. *Materials* 16(20):6616, 2023. doi:10.3390/ma16206616
17. ICH Q1A(R2) Stability Testing of New Drug Substances and Products. International Council for Harmonisation, Step 4, 2003.
18. Monton C., et al. Quality by Design-Driven Formulation Development of Cannabidiol Orally Disintegrating Tablets. *Scientifica* 2026:3553253, 2026. doi:10.1155/sci5/3553253 (PMCID:3519653)